parse_fastq.py 사용 설명서

1. 개요

lab11/src/parse_fastq.py 는 FASTQ 파일을 읽어서 read 개수와 첫 번째 read 의 이름, 서열, 길이를 화면에 출력하는 스크립트이다. 안에 있는 read_fastq 함수는 FASTQ 를 (이름, 서열, 품질) 튜플의 리스트로 바꿔 준다.

2. 실행 방법

```
cd lab11
python3 src/parse_fastq.py <FASTQ 파일>
```

- 인자는 FASTQ 파일 경로 하나만 받는다.
- 압축 파일(.fq.gz)은 바로 읽지 못한다. 먼저 gunzip -k 로 풀어서 쓴다.
- 외부 라이브러리 없이 파이썬 표준 기능만 쓴다.

3. 입력 형식

read 하나가 정확히 4줄로 된 FASTQ 를 받는다.

```
@read1 sample=A
ATGCGTACGTTAGC
+
IIIIIHHHGGFFEE
```

줄	예	내용
1줄	@read1 sample=A	@ + 이름
2줄	ATGCGTACGTTAGC	서열
3줄	+	구분자 (읽지 않고 건너뜀)
4줄	IIIIIHHHGGFFEE	품질 점수 (서열과 길이가 같음)

4. 실행 예시

read 4개짜리 샘플 파일로 실행한 결과이다.

```
$ python3 src/parse_fastq.py sample.fastq
read 개수: 4
첫 read 이름: read1 sample=A
첫 read 서열: ATGCGTACGTTAGC
첫 read 길이: 14
```

출력 항목	의미
read 개수	파일 안 read(4줄 묶음)의 수
첫 read 이름	첫 헤더에서 @ 를 뗀 나머지 전체

첫 read 서열	첫 read 의 2번째 줄
첫 read 길이	첫 read 서열의 글자 수

5. 코드 설명

read_fastq(filename)

1. f.readlines() 로 파일의 모든 줄을 한꺼번에 리스트로 읽는다.
2. range(0, len(lines), 4) 로 4줄씩 건너뛰며 read 하나씩 처리한다.
3. 각 read 에서
   - lines[i] → 끝의 줄바꿈을 지우고(rstrip()) 첫 글자 @ 를 뗀다([1:]) → 이름
   - lines[i + 1] → 서열
   - lines[i + 2] → + 줄이므로 쓰지 않는다
   - lines[i + 3] → 품질 문자열
4. (이름, 서열, 품질) 튜플을 리스트에 모아서 돌려준다.

다른 스크립트에서 쓰면 반환값은 아래와 같다.

```
[('read1 sample=A', 'ATGCGTACGTTAGC', 'IIIIIHHHGGFFEE'),
 ('read2 sample=A', 'GGCCTTAAGGCA',  'IIIIHHHGGFFE'),
 ...]
```

메인 부분

sys.argv[1] 로 받은 파일을 read_fastq 로 읽고, len(reads) 와 reads[0] 의 값들을 출력한다.

6. 주의할 점

상황	결과
파일 이름을 주지 않고 실행	IndexError: list index out of range (sys.argv[1] 없음)
빈 파일	reads[0] 에서 IndexError
파일 끝에 빈 줄이 더 있음	4줄 묶음이 어긋나 IndexError 가 나거나 이상한 read 가 생김
서열이 여러 줄로 나뉜 FASTQ	4줄 고정이라고 가정하므로 잘못 읽음
헤더에 공백이 있음	이름에 공백 뒤 내용까지 포함됨 (lab07 의 read_fasta 는 첫 단어만 씀)
아주 큰 파일	readlines() 가 파일 전체를 메모리에 올리므로 느리거나 메모리가 부족할 수 있음

- @ 로 시작하는지, + 줄이 맞는지, 서열과 품질 길이가 같은지는 확인하지 않는다.
- 품질 문자열(qual)은 읽어서 저장만 하고 출력에는 쓰지 않는다.
- 품질 점수를 숫자로 바꾸려면 Phred+33 기준으로 ord(문자) - 33 을 쓴다. 예: I → 40.