qual_summary.py 사용 설명서

1. 개요

lab11/src/qual_summary.py 는 FASTQ 파일의 품질 점수를 읽어서 전체 read 의 평균 품질을 숫자 하나로 출력하는 스크립트이다. read 마다 평균 품질을 구한 뒤, 그 값들을 다시 평균 낸다.

2. 실행 방법

```
cd lab11
python3 src/qual_summary.py <FASTQ 파일>
```

- 인자는 FASTQ 파일 경로 하나만 받는다.
- 압축 파일(.fq.gz)은 바로 읽지 못한다. 먼저 gunzip -k 로 풀어서 쓴다.
- 외부 라이브러리 없이 파이썬 표준 기능만 쓴다.
- 품질 문자는 Phred+33 인코딩(현재 Illumina 표준)이라고 가정한다.

3. 입력 형식

read 하나가 정확히 4줄로 된 FASTQ 를 받는다. 이 스크립트는 4번째 줄(품질)만 계산에 쓴다.

```
@read1 sample=A
ATGCGTACGTTAGC
+
IIIIIHHHGGFFEE
```

4. 실행 예시

read 4개짜리 샘플 파일로 실행한 결과이다.

```
$ python3 src/qual_summary.py sample.fastq
전체 read 평균 품질: 29.583333333333336
```

샘플 파일의 read 별 품질은 아래와 같다.

read	품질 문자열	길이	read 평균 품질
read1	IIIIIHHHGGFFEE	14	38.50
read2	IIIIHHHGGFFE	12	38.58
read3	IIIIIIIIHHHHGGGG	16	39.25
read4	####	4	2.00
출력값	(38.50 + 38.58 + 39.25 + 2.00) / 4		29.58

5. Phred 품질 점수

품질 문자 하나는 염기 하나의 정확도를 나타낸다. 문자의 ASCII 코드에서 33 을 빼면 Phred 점수 Q 가 된다.

문자	ASCII	Q = ASCII - 33	오류 확률
#	35	2	약 63%
+	43	10	10%
5	53	20	1%
?	63	30	0.1%
I	73	40	0.01%

- 오류 확률 = 10^(-Q/10)
- 보통 Q20 이상이면 쓸 만하고, Q30 이상이면 품질이 좋다고 본다.

6. 코드 설명

read_fastq(filename)

parse_fastq.py 의 함수와 같다. 파일 전체를 readlines() 로 읽고, 4줄씩 끊어서 (이름, 서열, 품질) 튜플의 리스트를 돌려준다. 3번째 줄(+)은 건너뛴다.

mean_quality(qual)

1. 품질 문자열의 글자를 하나씩 꺼낸다.
2. ord(ch) - 33 으로 Phred 점수로 바꿔 리스트에 모은다.
3. sum(scores) / len(scores) 로 평균을 돌려준다.

예: mean_quality("II##") → (40 + 40 + 2 + 2) / 4 = 21.0

메인 부분

1. sys.argv[1] 의 파일을 read_fastq 로 읽는다.
2. read 마다 mean_quality 를 구해서 total 에 더한다.
3. total / len(reads) 를 출력한다.

7. 결과를 해석할 때 주의할 점

출력값은 read 평균들의 평균이지 모든 염기의 평균이 아니다. read 길이와 상관없이 read 하나가 같은 비중을 가진다.

- 위 샘플에서 모든 염기 46개의 품질을 한꺼번에 평균 내면 35.61 이다.
- 그런데 스크립트 출력은 29.58 이다. 길이가 4 인 짧은 read4 의 낮은 품질이 read 하나 몫(1/4)을 통째로 차지하기 때문이다.
- 실제 Illumina 데이터처럼 read 길이가 모두 같으면 두 값은 같다. fastp 같은 도구로 trimming 해서 길이가 제각각이면 차이가 날 수 있다.

8. 오류가 나는 경우

상황	결과
파일 이름을 주지 않고 실행	IndexError: list index out of range (sys.argv[1] 없음)
빈 파일	ZeroDivisionError: division by zero (len(reads) 가 0)
품질 줄이 빈 read 가 있음	mean_quality 에서 ZeroDivisionError
파일 끝에 빈 줄이 더 있음	4줄 묶음이 어긋나 IndexError 가 나거나 값이 틀어짐
서열이 여러 줄로 나뉜 FASTQ	4줄 고정이라고 가정하므로 잘못 읽음
Phred+64 인코딩(오래된 Illumina)	오류는 없지만 점수가 31 씩 높게 나옴
아주 큰 파일	readlines() 가 파일 전체를 메모리에 올리므로 느리거나 메모리가 부족할 수 있음

- 서열과 품질 문자열의 길이가 같은지는 확인하지 않는다.
- read 이름과 서열은 읽기만 하고 쓰지 않는다.